

# SVM (Support Vector Machine)：支持向量机模型

应用：实现对数据集的线性 / 非线性预测，分类以及对未知样本点的预测。

目标函数：

$$J(w, b, \varepsilon) = \arg \min_{w, b}$$

$$\max \min(d_\varepsilon)$$

$\Rightarrow$  所有样本点到某个

分割面的最小距离，也为

分割带最

宽的超平面

分割面： $w'x + b = 0$ ,

$w, b$  为分割面参数

分割带边界虚线上点  
称为 支持向量。为  
SVM 模型核心点...

△ 分割带越宽模型泛化性越好，预测样本能力与可信度越高。

此时的分割面为最优超平面。

函数间隔：

$$\hat{y}_i = y_i \cdot (w' x_i + b)$$

样本点所属类别

$\geq 1 \Rightarrow y_i$  预测  
为 +1

$\leq -1 \Rightarrow y_i$  预测  
为 -1

因此得证：

线性可分 SVM 模型的

函数间隔  $\hat{y}_i \geq 1$ , 此

为必要条件

几何间隔：

$$Y_i = \frac{\hat{y}_i}{\|w\|} = \frac{y_i \cdot (w' x_i + b)}{\|w\|} = \frac{|w' x_i + b|}{\|w\|} = \frac{d_\varepsilon}{\|w\|}$$

即为

超平面距离

超平面:  $wx + b = 0$

$w, b$  同比个 对其无影响, 但影响 函数  
间隔  $\hat{y}_i$ , 因此必须做标准化处理.

目标函数

SVM

线性可分模型:

非线性可分模型:

$$J(w, b, \xi) = \arg_{w, b} \max \min(d_i) = \arg_{w, b} \max \frac{1}{\|w\|} \cdot \min(\hat{y}_i)$$

线性可分模型:

此前由函数间隔已知  $\hat{y}_i \geq 1 \Rightarrow \min \hat{y}_i = 1$

$$\therefore J(w, b, \xi) = \arg_{w, b} \max \frac{1}{\|w\|} \cdot \min(\hat{y}_i)$$

$$\begin{cases} \max \frac{1}{\|w\|} \\ \text{s.t. } \hat{y}_i \geq 1 \end{cases}$$

$$\begin{cases} \min \frac{1}{2} \|w\|^2 \\ \text{s.t. } \hat{y}_i \geq 1 \end{cases}$$

函数间隔约束.

拉格朗日乘子法:

要求: ① 目标函数为  $\min(f(x))$  ② 有约束条件: s.t.  $g(x) \leq 0$

原理: 利用 拉格朗日对偶性 将原始最优化问题 转换为对偶问题,

$$\begin{aligned} \min(f(x)) &= \min_x \max_{\lambda} (L(x, \lambda)) = \min_x \max_{\lambda} (f(x) + \sum_{i=1}^k \lambda_i g_i(x)) \\ &= \max_{\lambda} \min_x (f(x) + \sum_{i=1}^k \lambda_i g_i(x)) \end{aligned}$$

$$\begin{aligned}
 & \text{e.g. } \min_{w,b} \frac{1}{2} \|w\|^2 = \max_{\alpha} \min_{w,b} \left( \frac{1}{2} \|w\|^2 + \sum_{i=1}^n \alpha_i (1 - \hat{y}_i) \right) \\
 & = \max_{\alpha} \min_{w,b} \left( \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i y_i \underbrace{x_i(w^T x_i + b)}_{\sum_{i=1}^n \alpha_i} \right)
 \end{aligned}$$

拉格朗日乘子法的目标函数

求解  $w, b$ ：对拉格朗日乘子法得到的目标函数求偏导，令导函数为0。

$$\left\{
 \begin{array}{l}
 \frac{\partial L(w, b, \alpha)}{\partial w} = 0 \Rightarrow w - \sum_{i=1}^n \alpha_i y_i x_i = 0 \quad ① \\
 \frac{\partial L(w, b, \alpha)}{\partial b} = 0 \Rightarrow \sum_{i=1}^n \alpha_i y_i = 0 \quad ②
 \end{array}
 \right.$$

将 ①, ② 代入  $L(w, b, \alpha)$  得：

$$\begin{aligned}
 \min_{w,b} \frac{1}{2} \|w\|^2 &= \max_{\alpha} \min_{w,b} \left( \frac{1}{2} \|w\|^2 - \sum_{i=1}^n \alpha_i y_i x_i (w^T x_i + b) + \right. \\
 &\quad \left. \frac{1}{2} \cdot w^T w \right) \quad ① \\
 &= \max_{\alpha} \left( -\frac{1}{2} \cdot w^T \sum_{i=1}^n \alpha_i y_i x_i + \sum_{i=1}^n \alpha_i - 0 \right) \quad ② \\
 &= \max_{\alpha} \left( -\frac{1}{2} \cdot \sum_{i=1}^n \sum_{j=1}^n \alpha_i y_i x_i \alpha_j y_j x_j + \sum_{i=1}^n \alpha_i \right) \\
 &\quad w^T
 \end{aligned}$$

# 新目标函数

对新目标函数求解：

$$\Leftrightarrow \left\{ \begin{array}{l} \min_{\alpha} \left( -\frac{1}{2} \cdot \sum_{i=1}^n \sum_{j=1}^n \alpha_i \cdot y_i \cdot X_i \cdot \alpha_j \cdot y_j \cdot X_j - \sum_{i=1}^n \alpha_i \right) \end{array} \right.$$

$$\left. \begin{array}{l} \text{s.t. } \sum_{i=1}^n \alpha_i \cdot y_i = 0 \Rightarrow \text{原始目标函数偏导得} \\ \alpha_i \geq 0 \Rightarrow \text{拉格朗日乘子约束.} \end{array} \right.$$

$$w'x + b = 0$$

解得  
—

$$\left\{ \begin{array}{l} \hat{w} = \sum_{i=1}^n \hat{\alpha}_i y_i x_i \\ \hat{b} = y_i - \sum_{j=1}^n \hat{\alpha}_j y_j (\underbrace{x_i \cdot x_j}_{\text{内积}}) \end{array} \right.$$

i-th example  $x_i$ .

$$f_k(i) = \theta^T f_i = \theta_0 + \theta_1 f_1 + \dots + \theta_k f_k -$$

$$\geq 0 \Rightarrow y=1$$

*previu*y

k-th landmark  $l^{(k)}$ !

$\Delta \quad \theta^T f$  is the hypothesis function of kernel SVM.

$$\underbrace{C \cdot A + B}_{\text{Logistic Regression}}$$

$$A = \sum_{i=1}^m y_i g(h_\theta(x^{(i)})) \cdot \dots$$

$$B = \frac{1}{2m} \sum_{i=1}^m \theta_i^2$$